

INVESTIGACIÓN TÉCNICA

Codificación de Caracteres y Formatos de Archivos

Nombre: Samyl Enrique Jimenez Martinez

Matrícula: 2026-0292

Materia: Programación para mecatrónicos

1. CODIFICACIÓN DE CARACTERES

La codificación de caracteres es el proceso mediante el cual se asigna un número o valor binario a un carácter específico (letras, números, signos de puntuación y símbolos de control) para permitir su almacenamiento, procesamiento y transmisión en sistemas informáticos y redes de comunicación.

| ASCII (American Standard Code for Information Interchange)

Desarrollado a principios de la década de 1960, ASCII es uno de los estándares de codificación más antiguos y fundamentales. Utiliza un sistema de **7 bits** para representar un total de 128 caracteres únicos (del 0 al 127).

- **Rango:** Incluye letras del alfabeto inglés (mayúsculas y minúsculas), números del 0 al 9, signos de puntuación básicos y 32 caracteres de control no imprimibles (como salto de línea o tabulación).
- **Limitación:** Al estar diseñado exclusivamente para el idioma inglés, carece de soporte para caracteres acentuados, la letra "ñ", diéresis o alfabetos no latinos (como el cirílico, griego, árabe o ideogramas asiáticos). Posteriormente surgieron extensiones de 8 bits (como ISO-8859-1), pero resultaban incompatibles entre sí.

| UTF-8 (Unicode Transformation Format - 8-bit)

UTF-8 es la codificación dominante en la World Wide Web y los sistemas operativos modernos. Es una codificación de **longitud variable** que utiliza entre 1 y 4 bytes (8 a 32 bits) para representar cualquier carácter del repertorio Unicode.

- **Compatibilidad:** Es 100% retrocompatible con ASCII. Los primeros 128 caracteres Unicode coinciden exactamente con ASCII y se codifican usando un solo byte, lo que optimiza enormemente el espacio.
- **Eficiencia:** Utiliza bytes adicionales sólo cuando es necesario para caracteres especiales, ideogramas o emojis, convirtiéndolo en el estándar ideal para la transferencia de datos globales.

| UTF-16 (Unicode Transformation Format - 16-bit)

A menudo confundido o erróneamente denominado "UTF-18" (el cual no existe formalmente en los estándares tecnológicos), **UTF-16** es una codificación de longitud variable que utiliza unidades base de **16 bits (2 bytes)**.

- **Mecanismo:** Los caracteres más comunes del plano básico se codifican en un solo bloque de 16 bits (2 bytes), mientras que los caracteres complementarios (como ideogramas raros o emojis) requieren dos bloques (4 bytes) mediante pares subrogados.
- **Uso común:** Es el estándar interno utilizado en los entornos de ejecución de Java, Microsoft Windows API y JavaScript. Su principal desventaja frente a UTF-8 es que duplica el tamaño de los archivos compuestos principalmente por texto en inglés o caracteres ASCII básicos.

2. FORMATOS DE ALMACENAMIENTO E INTERCAMBIO DE DATOS

Los formatos de archivos estructurados definen las reglas semánticas y sintácticas para organizar la información, permitiendo que diferentes aplicaciones interpreten los datos de forma unificada.

| JSON (JavaScript Object Notation)

JSON es un formato de texto ligero y de estructura simple, basado en la sintaxis de objetos de JavaScript, pero completamente independiente del lenguaje. Se fundamenta en dos estructuras principales: colecciones de parejas de nombre/valor (objetos) y listas ordenadas de valores (arreglos).

- **Ventajas:** Es extremadamente legible para los humanos, fácil de parsear por las computadoras y muy compacto en comparación con formatos más verbosos.
- **Aplicación principal:** Es el estándar de facto para el intercambio de datos en APIs web modernas y la comunicación entre clientes y servidores de aplicaciones.

| XML (Extensible Markup Language)

XML es un lenguaje de marcado extensible desarrollado por el W3C, diseñado para almacenar y transportar datos estructurados centrándose en el significado de la información a través de etiquetas personalizadas.

- **Características:** Utiliza una estructura arbórea estricta con etiquetas de apertura y cierre (ej. `<usuario>...</usuario>`). Permite la validación formal de su estructura mediante esquemas DTD o XSD.
- **Aplicación principal:** Ampliamente adoptado en configuraciones de sistemas corporativos, documentos de oficina (como los formatos .docx o .xlsx), protocolos antiguos de servicios web (SOAP) y sistemas de facturación electrónica estatales.

| CSV (Comma-Separated Values)

CSV es uno de los formatos más antiguos y simples para almacenar datos en forma de tabla. Consiste en un archivo de texto plano donde cada línea corresponde a una fila de datos y los campos están separados por un delimitador, tradicionalmente una coma (,) o un punto y coma (;).

- **Ventajas:** Su estructura minimalista carece de metadatos complejos u overhead de formato, lo que genera archivos muy ligeros y de altísima compatibilidad.
- **Aplicación principal:** Es la herramienta estándar para exportar e importar grandes volúmenes de datos numéricos o bases de datos entre hojas de cálculo (Microsoft Excel, Google Sheets) y sistemas de análisis de datos (Python, R).

3. MATRIZ COMPARATIVA DE FORMATOS

Formato	Tipo de Estructura	Legibilidad Humana	Verbosidad / Peso	Uso Principal
JSON	Pares Clave-Valor / Árbol	Alta	Baja / Ligero	APIs Web y Servicios REST
XML	Etiquetas Jerárquicas / Árbol	Media	Alta / Pesado	Configuraciones e Intercambio Empresarial
CSV	Tabular (Filas y Columnas)	Alta (en lector)	Mínima / Muy ligero	Bases de Datos y Hojas de Cálculo

Nota Técnica sobre UTF-18: En la literatura oficial de consorcios tecnológicos como Unicode o ISO, no existe la codificación "UTF-18". Los estándares globales normalizados vigentes son UTF-8, UTF-16 y UTF-32. Se asume en este reporte el análisis de UTF-16 debido a la nomenclatura secuencial de desarrollo.